

분류

- 가성치 벡터 w 를 얻고 있으면, 새로운 특징벡터 x 가 주어진 경우 패턴 분류를
자동에서 출력값을 계산할 수 있음 \Rightarrow 가성치 벡터 w 를 얻기 위해 사용하는 x 가 아닌 새로운 x

$$\Rightarrow 0 = \tau(w \cdot x) \quad \left(\begin{matrix} \text{정확도} \\ w^T w \geq 1 \\ \text{otherwise} \rightarrow -1 \end{matrix} \right) \text{example}$$

- 리본! 오르는 값 \Rightarrow Output
 - 리본! 오르는 값 \Rightarrow Input
- \Rightarrow * 리본! w 가 주어진 상황에서 분류 (최종판정)
 $\hookrightarrow x$ 가 주어진 계산으로 인해 오르는 리본

학습 $\rightarrow x$ 와 label이 주어진

- 학습 과정에서는 특징벡터 x 와, 이미 대응하는 0 과 1 이 주어진 있음 $\Rightarrow 0 = \tau(w \cdot x)$
- 오르는 값 w 를, samples를 저대로 분류할 수 있도록 하는 것이 목적
- 훈련값이란 samples의 개수가 아주 많고, 이 모든 samples를 잘 분류할 w 를 찾는 것
 \hookrightarrow model이 모든 데이터에 잘 맞는 w 를 찾고, 평가하는 것을 있음
- 최적해를 찾기 위해 최적화 알고리즘 사용
 \hookrightarrow 인공신경망의 학습
 \hookrightarrow 인공신경망 모델에서 사용되기 용이한 방법 (model, data에 대해 최적화 가능함)

PLA (Perceptron Learning Algorithm) \Rightarrow 간단한 학습, 이해

- 벡터 w 가 어떤 값을 가져야 제대로 분류할 수 있게 되나? 최적화 알고리즘이 있음

- 최적화를 위해선 비용함수 (목적함수)가 먼저 정의되어야 함

\hookrightarrow 어떤 점들을 가장 만족하는 값을 찾음

\hookrightarrow 어떤 점들을 가장 만족할 때 가장 목적함수가 작을 때 모든 점을 올바르게 분류할 수 있는 w 를 찾는 것
 \hookrightarrow 목적함수의 값으로 나타내는 것 (정, 부정)을
 \hookrightarrow 점들에서 거리를 나타내줌

\Rightarrow 최적화 비용함수를 먼저 정의해 알맞은 어떤 w 가 좋은 성능을 내지 않는 것 있음

* 모든 점을 최적화하여 정답

$$J(w) > 0 \quad (\text{어떤 점이 분류하지 못함} \Rightarrow \text{오류가 있음})$$

$$J(w) < 0 \quad (\text{비율 함수가 0보다 크도록 함})$$

$$J(w) \text{ 값이 최솟거나 최저 값을 가지는 w 를 찾는 것}$$

$$J(w) \text{ 값이 0이 되는 w 를 찾는 것}$$

성능을 $J(w)$ 값이 작아짐

\hookrightarrow 어떤 점들을 가장 만족하는 w 를 찾는 것

\hookrightarrow 어떤 점들을 가장 만족하는 w 를 찾는 것

1. Data point x_i , 대응하는 label $y_i \leftarrow 1$ or -1

$$(x_1, y_1), \dots, (x_n, y_n)$$


$$x_k = [x_{k0}, x_{k1}, \dots, x_{kd}]^T \Rightarrow \text{Data point (vector } x_k)$$

2. 비용함수 $J(w) \Rightarrow$ 목적함수가 먼저 정의

$$J(w) = \sum_{x_k \in T} -y_k (w \cdot x_k)$$

$\hookrightarrow w$ 를 사용해서 분류할 때, 분류에 실패하면 대수적인 값

$$-y_k (w \cdot x_k) > 0 \Rightarrow \text{비율 함수가 목적에 맞게 잘 정의 되었는지 확인}$$



\Rightarrow 모든 samples가 만족하도록 비용함수가 작아짐

3. 비용함수를 가중치 w 에 대해 미분

$$\Rightarrow \frac{\partial J(w)}{\partial w_i} = \sum_{x_k \in T} \frac{\partial (-y_k (w_0 x_{k0} + \dots + w_d x_{kd}))}{\partial w_i} = \sum_{x_k \in T} -y_k \cdot x_{ki} \quad (\text{가중치 } w_i \text{에 대한 미분})$$

4. 가중치 벡터를 업데이트

$$w_i \leftarrow w_i + \eta \sum_{x_k \in T} y_k \cdot x_{ki} \quad (i = 0, 1, \dots, d)$$

\hookrightarrow learning rate (constant) \Rightarrow 학습률
 $\hookrightarrow w$ 가 update 되는 때마다 업데이트 비율이
 $\hookrightarrow \eta$ 를 작게 하면 업데이트 비율을 낮추고 업데이트 양을 줄여
오류를 줄임 (성능이 좋아짐)

$$\Rightarrow w \text{를 재조정}$$

\Rightarrow 1, 2, 3, 4의 과정을 반복하여 최적화하여 수행 (J가 0이 될 때까지)

\hookrightarrow 분류 시 특정한 samples의 수가 작을 때
 \hookrightarrow (특정점과 중심이 다르면)

• PLA는 순서쌍이 순서쌍 분리가 가능하면 반드시 최적화할 수 있음

• 순서쌍 분리가 순서쌍 분리가 안 되면 부족한 반복

\hookrightarrow (가중치)가 항상 순서쌍 분리가 안 되는 것이 발생하면 분리할 수 없음
또 분리하지 않는 해를 얻고 싶으면 중간에 포기 선택하는 것

J가 0이 되는 것

오류가 0이 되는 것