

배치 경사하강법 (BGD)

- Input : 훈련집합 X, Y , 학습률 ρ
- Output : 최적해 θ^*

1. 난수를 생성해서 초기에 θ 를 설정.
2. Repeat $\{x_1, x_2, \dots, x_n\}$ Def, n번의 그라디언트 계산 가능
3. X 에의 샘플에 대해 그라디언트 계산: $\nabla_1, \nabla_2, \dots, \nabla_n$ (모든 sample)
4. $\nabla_{total} = \frac{1}{n} \sum_{i=1}^n \nabla_i$ ← 평균값
5. $\theta \leftarrow \theta - \rho \nabla_{total}$ ← 그라디언트 방향으로 update θ 가 변함
6. $\theta^* = \theta$

(종료조건) $\| \nabla_{total} \| < \epsilon$ \Rightarrow 수렴적으로 최정해를 얻을 수 있지만 수렴이 느릴 수 있음

스토캐스틱 경사하강법 (SGD)

1. 난수를 생성해서 초기에 θ 를 설정한다.
2. Repeat
3. X 의 샘플 하나를 뽑음.
4. $for(i=1 to n)$
5. i 번째 sample에 대해 그라디언트 ∇_i 계산
6. $\theta \leftarrow \theta - \rho \nabla_i$
7. (종료조건)
8. $\theta^* \leftarrow \theta$

- SGD에서는 한 번에 하나의 그라디언트를 계산하고 즉시 매개변수를 업데이트.
- 전체 샘플에 대해 다 업데이트하는 것을 1epoch라고 부름. → 학습의 정량화
- 새로운 epoch마다 샘플의 순서를 섞어서 무작위성을 부여하고, 스토캐스틱이라고 함.
- \Rightarrow Data의 특성이 어느 정도인지 알 수 있음

로지스틱 회귀 (Logistic Regression)

$\Rightarrow S = \frac{w^T x}{||w||}$ ← 선형성

- 선형분류에서는 신호(결과) S 를 ± 1 로 만들어서 출력으로 사용.
 \rightarrow Thresholding (결정의 코지치 제정할 가능)
- $\rightarrow ex) h(x) = \text{sign}(w^T x)$
- 선형회귀에서는 신호 S 자체를 출력으로 사용함.
 $\rightarrow ex) h(x) = w^T x$
- 로지스틱 회귀에서는 신호 S 를 0과 1 사이의 값으로 만들어서 출력.
 \rightarrow 로지스틱 함수.
$$\theta(x) = \frac{e^x}{1+e^x} \in [0, 1]$$

$\rightarrow h(x) = \theta(w^T x)$ (S가 0.5보다 높을 때 1, 낮을 때 0)

S가 -902.7 이하일 때

S가 0.37 이상일 때

Compare

- 선형분류에서는 이전분류를 통해 ± 1 로 결과를 출력함.
- 로지스틱 회귀에서는 이전분류결과에서 결과를 직접 출력함.
 \Rightarrow 이전분류결과를 로지스틱 회귀로 \rightarrow 연속적으로 가능.
(이전분류 결과가 분류할 수 있음)
- 선형분류에서 사용하는 $\text{sign}()$ 함수는 hard threshold라고 부름.
- 로지스틱 회귀에서 사용하는 Logistic function은 soft threshold
- 이 Sigmoid function이라고 부름 \Rightarrow 이를 Sigmoid 함수로 사용해서 문제를 푼다.
S가 0.5

Logistic Regression

• 학습하고자 하는 목표함수를 $f(x)$ 라고 하자.

$$f(x) = P[y=+1|x] \leftarrow \text{이전분류결과}$$

\leftarrow y 가 +1일 확률

\leftarrow y 가 -1일 확률 $P[y=-1|x]$


\Rightarrow 수렴적인 함수로 사용해서 출력을 도출함

- * 목표함! 목표하여 y 가 주어진 샘플에서 출력값(Label) y 와 +1의 함수를
- $\rightarrow f(x)$ 목표함수는 선지로는 안 가능, 훈련데이터셋을 바탕으로 θ 설정
 \rightarrow 데이터가 주어진 목표함수를 찾아야 함. (안정하지 않으면 학습할 수 없음)
- \rightarrow 추정해 낸 함수는 $h(x)$ 라고 쓰고, 가설(hypothesis)이라 부름.

* 훈련데이터셋 X, Y 는 어떤 확률분포 $P(y|x)$ 로부터 얻어진 것이라 생각

\rightarrow Input data (특정 데이터) x 가 주어졌을 때, 출력데이터 y 를 얻을 확률 (실제 문제) : 예측해야 하는 보정할 문제

$$P(y|x) = \begin{cases} f(x) & \text{for } y=+1 \\ 1-f(x) & \text{for } y=-1 \end{cases} \Rightarrow \text{입력받은 데이터에 대한}$$



- \Rightarrow 실제 $f(x)$ 를 어떻게 잘 추리는가에 따라
- \Rightarrow 정렬되지 않은 데이터 하위분류 (Parameter learning)
- \rightarrow 모든 data point를 보낼 수 있음
- * 실용적! 수렴적으로 근사하게 값을 보낼 수 있음.

오차 정의하기

- $h(x)$ 가 목표함수 $f(x)$ 를 잘 보시라는지 여부를 판단하기 위해, 오차를 측정할 수 있거나 함.

ex) $x = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, x_T = \begin{bmatrix} 1 \\ 0.1 \end{bmatrix} \rightarrow ||x_T - x||_2$

- 로지스틱 회귀에서 오차를 측정하는 방법 중 하나로 무차이를 사용하는 것.
 $\Rightarrow f(x)$ 를 보들 $h(x)$ 는 약 2.14는. \Rightarrow 간접적으로 측정함.

무도 (기능도, Likelihood)

- 기능도 $h(x)$ 가 실제확률분포 $P(y|x)$ 를 표현하고 있냐를 판단함.
- 훈련데이터의 입력데이터 x 를 무도한 때 출력 데이터 y 를 (실제값)
- 얻을 기능도 \Rightarrow x 를 x , y 를 y
- ex) x 가 1, 1, 1 이 주어진다면 y 가 0, 1, 1 이 주어진다면 y 를 예측할 수 있음 (즉, 이진분류)
- \rightarrow 기존 Database이 주어진다면 $model$ 을 찾음
- \Rightarrow $model$ 을 찾음 \rightarrow 실제 오차와 모델 오차가 나뉘어 있음