

신경망 구조

$$(h_1, h_2, h_3, h_4) = \underbrace{(x_1, x_2)}_{\substack{\text{특성 벡터} \\ (1 \times 4)}} \underbrace{\begin{pmatrix} w_{11} & w_{12} & w_{13} & w_{14} \\ w_{21} & w_{22} & w_{23} & w_{24} \end{pmatrix}}_{\substack{\text{가중치 행렬} \\ (2 \times 4)}} + \underbrace{(b_1, b_2, b_3, b_4)}_{\substack{\text{bias} \\ (1 \times 4)}}$$

(Input d, output d) (2×4) $(N \times 4)$

$$\Rightarrow \underline{h} = \underline{x} \cdot \underline{w} + \underline{b}$$

(MLP → perception의 값)
(각 층에서 layer로 들어)

$$\underline{H} = \underline{x} \cdot \underline{w} + \underline{b} \leftarrow \text{Affine Layer}$$

• Sigmoid Function (정규화)

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

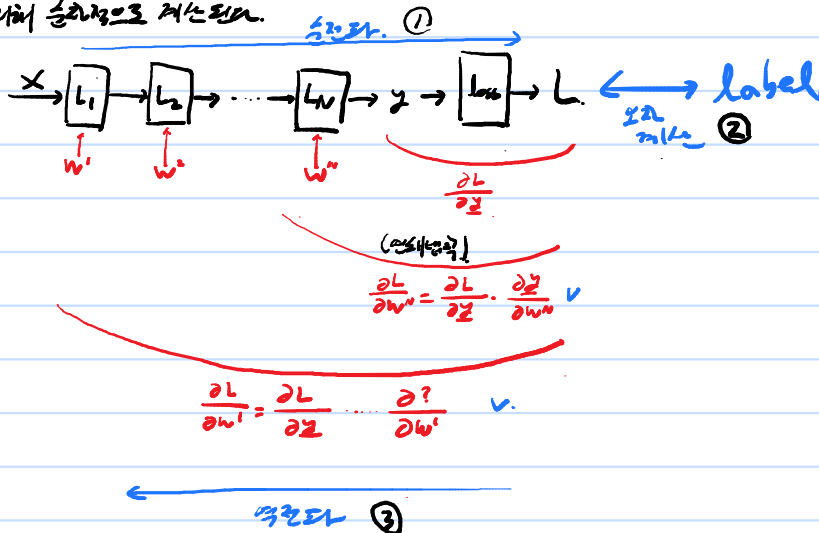
* $\underline{x} \rightarrow \text{Affine} \rightarrow \text{Sigmoid} \rightarrow \text{Affine} \rightarrow \dots$ (순전파, propagation) → 순차적으로 레이어 진행

역전파 (Error Back-propagation)

- 신경망의 기저학습과정에서, 주어진 학습데이터 (특성 벡터)에 대해 손실값을 계산하는 단계.
- 신경망의 매개변수를 업데이트하기 위해서는 손실값이 그라디언트를 계산해야 한다.
- 손실함수 L , 매개변수 w 에 대하여: (매개변수 w 에 대한 기울기)

$$\frac{\partial L}{\partial w} = \begin{pmatrix} \frac{\partial L}{\partial w_{11}} & \dots & \frac{\partial L}{\partial w_{1n}} \\ \vdots & & \vdots \\ \frac{\partial L}{\partial w_{m1}} & \dots & \frac{\partial L}{\partial w_{mn}} \end{pmatrix} \in \mathbb{R}^{m \times n}, w \in \mathbb{R}^{m \times n}$$

- 신경망은 여러 개의 perception이 순차적으로 연결된 형태이므로, gradient는 연쇄법칙에 의해 순차적으로 계산된다.



- 신경망의 출력에서 입력 방향으로 거꾸로 진행되는 것들을 통해 역전파하는 과정을 볼

연쇄법칙 (Chain rule)

- 함수값에 대한 미분법칙.
- 역전파 과정에서 사용하는.

ex) $y = f(x)$, $z = g(y)$ 이 때

$$\rightarrow z = g(f(x))$$

$$\rightarrow \frac{\partial z}{\partial x} = \frac{\partial z}{\partial y} \cdot \frac{\partial y}{\partial x}$$