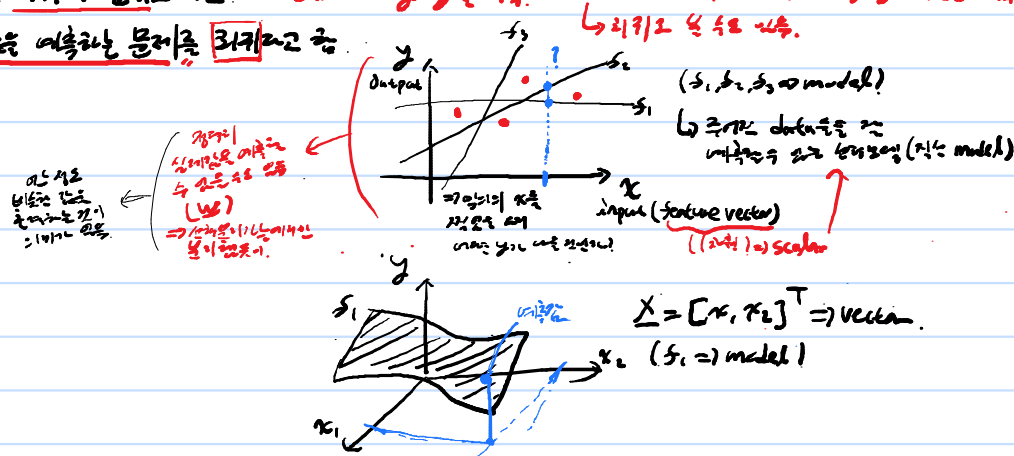


회귀 (Regression)

- 주어진 입/출력 데이터쌍들을 바탕으로, 출력을 예측하는 형태의 학습 (패턴/모델 학습)
- 예측은 회귀와 분류로 구분
 - * 분류: Category를 예측. \Rightarrow 학습값을 바탕으로 분류에서 Category의 값을 예측하는 것으로 학습.
- 실수값을 예측하는 문제들을 회귀라고 함



- 선형 회귀 모델.
 - $\Rightarrow y = w_1 x_1 + w_0$ (1차원)
 - $w_2 x_2 + w_1 x_1 + w_0$ (2차원)

일반적인 선형 회귀

- $X = \{x_1, x_2, \dots, x_n\} \rightarrow i\text{-th element}$
- $y = \{y_1, y_2, \dots, y_n\}$ $x_i = [x_{i1}, x_{i2}, \dots, x_{id}]^T$ (특정값의 d차원 벡터)
- $\Rightarrow w_1 x_{i1} + w_2 x_{i2} + \dots + w_d x_{id} = x_i \cdot w = y_i \rightarrow$ 선형 방정식 (d차원 n개 행)
- 위의 방정식을 정칙히 만족하려면, 선형 회귀 모델을 사용하여 모든 샘플을 정칙하게 만들 수 있음. \rightarrow 모든 샘플이 하나의 직선 상에 놓인 경우. (V.I)
- 주어진 방정식에 대해 모든 샘플은, 매번 d개이고 방정식이 개수가 n개인 선형 시스템으로 해를 찾는 문제와 같음. \rightarrow 해가 복수일 경우도 있고, 없거나 무한히 많은 해가 있을 수도 있음.

$$\Rightarrow Xw = y$$

$$X = \begin{pmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_n^T \end{pmatrix} \in \mathbb{R}^{n \times d}, w = [w_1, \dots, w_d]^T \in \mathbb{R}^d$$

$$y = [y_1, \dots, y_n]^T \in \mathbb{R}^n$$

- 선형 회귀 문제에서는 모든 sample들이 하나의 직선 상에 놓이는 경우는 극히 드물음.
- 위의 방정식을 정칙히 만족하는 모든 해를 찾는 것은 어렵음. (복잡함)
- * 대신, 가장 근접하게 만족하면서 오차를 최소화하는 모든 해를 찾아야 함.
 - \hookrightarrow norm을 찾는 방법
 - * PLA에서는 (복잡) \Rightarrow 불완전 최적화 문제를 최소화

선형 회귀의 목적 함수 (비용 함수)

$$\Rightarrow J(w) = \frac{1}{2} \sum_{i=1}^n (x_i^T w - y_i)^2$$

\Rightarrow 정칙히 만족하면 이 값이 작아짐

\Rightarrow 여러개의 샘플이 만족하도록 하는 것 (합성 문제)

$$= \frac{1}{2} \|Xw - y\|_2^2$$


\Rightarrow J를 최소화하는 w를 찾아야 함

$$= \frac{1}{2} (Xw - y)^T (Xw - y)$$

• 선형 회귀의 목적 함수는 2차 함수 (quadratic) 형태로 구성.

• 이는 각 sample별로 계산한 오차 제곱을 모두 더한 것.

\Rightarrow J의 최소를 찾기 위해 미분법을 통해 미분기가 0이 되는 지점을 찾음



$$\frac{\partial J(w)}{\partial w} = X^T X w - X^T y = 0$$

$$\Rightarrow w = (X^T X)^{-1} \cdot X^T y \equiv w^*$$

\hookrightarrow 정칙된 수학적 성질이 존재 (보통 x)

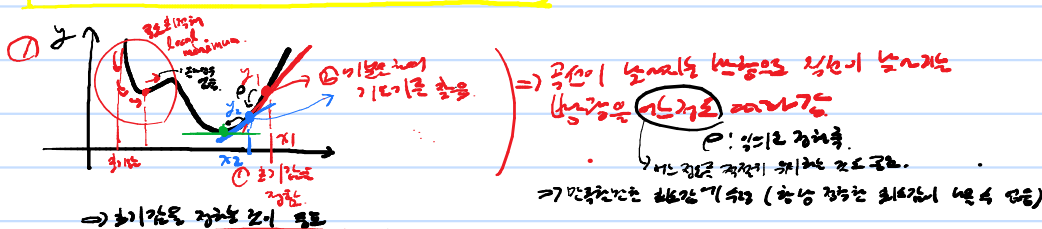
$\therefore y_{pred} = x_{new} \cdot w^*$

선형 회귀와 선형 분류의 차이

- 선형 분류에서는 회귀를 위해 선형 판별기 (PLA)는 사용. 이 입/출력 쌍이 완전히 선형 separable 여부 (합성 가능 여부) (선형 불가능 여부)
- 선형 회귀에서는 회귀를 위해 선형 회귀는 사용. 판별기 회귀를 찾는 수 있음.
 - \hookrightarrow ex) step func. etc.

\hookrightarrow 입력 데이터가 선형 분할 가능. (비선형에서는 불가능함) \Rightarrow 각각의 비선형으로 각 지점 해결.

경사 하강법 (Gradient Descent Method)



- ① \Rightarrow 회귀를 위한 방법
- ② \Rightarrow 경사 하강법 사용
- \Rightarrow 경사 하강법은 미분법을 사용하여 최적점을 찾는 방법.
- \Rightarrow 경사 하강법은 미분법을 사용하여 최적점을 찾는 방법.

- 회귀 위치에서 비선형 분할을 찾아 모순적 내지거나 회귀를 찾는 수리적 방법
 - \hookrightarrow 선형 회귀에서는 한 번에 회귀를 찾는 수 있음 (일반적인 수리에서는 불가능함)
- 비선형으로 이동해서 비선형 분할 (2차 미분 등)을 찾는 방법
 - \hookrightarrow 비선형의 비선형 분할

• 2차 미분을 이용하여 근사하기 위해 학습률 (learning rate)을 찾음.

$$\theta = \theta - \alpha \frac{\partial J}{\partial \theta}$$

\hookrightarrow model을 업데이트 하는 parameter

• 2차 미분을 계산하는 미분기 코딩으로 주어진 데이터 쌍을 사용