

## # 우도의 정의

→ 확률 변수  $X$  가  $n$  개면  $\theta$  이 대한 확률분포  $P_\theta(X)$  을 가지고,  $X$  를 시행하여 특정 데이터  $x$  를 얻었다고 하자.

•  $\theta$  의 가능도(우도) 함수는  $L(\theta|x)$  이고, 다음과 같음.

$$L(\theta|x) = P_\theta(x) = P_\theta(X=x)$$

$\downarrow$   $P_\theta$  (가설변수)
 $\downarrow$  관측변수

→ 확률변수  $X$  가 변한다면, 전체 우도는 각 샘플의 우도의 곱.

- $L(\theta|x) \neq p(\theta|x)$
- $p(\theta|x)$ :  $x$  가 주어졌을 때  $\theta$  의 확률  
(Posterior probability of  $\theta$  given  $x$ )

## # 우도와 확률 비교 예시.


• 독립적인 어떤 모델(확률분포)이 먼저 주어졌고 상황까지 특정 데이터셋에 대해 얻을 수 있음.

ex) (주어진 확률분포) 동전 던지기의 앞/뒷면이 나올 확률은 각각  $\frac{1}{2}$ .

(특정 데이터셋이 나온 경우)

→ 특정 데이터셋 {위, 위, 아래}를 얻은 확률은  $(\frac{1}{2})^3 = \frac{1}{8}$

→ 우도는 어떤 데이터셋이 먼저 주어진 상황에서 특정 데이터에 대해 얻을 수 있음.



ex) 특정 데이터셋 {위, 위, 아래}

→ 1. (위  $\frac{2}{3}$ , 아래  $\frac{1}{3}$ )인 모델.  $\Rightarrow$  우도 =  $\frac{2}{3} \cdot \frac{2}{3} \cdot \frac{1}{3} = \frac{4}{27}$ .  $\Rightarrow$  우도보다 큰 모델.

→ 2. (위  $\frac{1}{2}$ , 아래  $\frac{1}{2}$ )인 모델  $\Rightarrow$  우도 =  $\frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{8}$ .

## # Logistic Regression (비선형성 모델)

1.  $h(x) = \sigma(w^T x)$

$$\sigma(s) = \frac{e^s}{1+e^s}$$

2. 확률값과 하는 대응

$$P(y|x) = \begin{cases} \sigma(x), & y=+1 \\ 1-\sigma(x), & y=-1 \end{cases} \rightarrow P(y|x) = \begin{cases} h(x), & y=+1 \\ 1-h(x), & y=-1 \end{cases}$$

$$P(2|x) = \sigma(y \cdot w^T x)$$

$$\begin{aligned} 1-\sigma(s) &= \sigma(-s) \sim \frac{e^{-s}}{1+e^{-s}} = \frac{1}{1+e^s} \\ \rightarrow 1-\sigma(s) &= \frac{1+e^s - e^s}{1+e^s} = \frac{1}{1+e^s} = \frac{e^{-s}}{e^{-s}+1} = \frac{e^{-s}}{1+e^{-s}} = \sigma(-s) \end{aligned}$$

3. 훈련데이터셋이 포함된  $x = \{(x_1, y_1), \dots, (x_n, y_n)\}$  등이 모두 독립적으로 생성된 것이라 가정하면, 해당 입력데이터  $x_1, \dots, x_n$ 들이 독립일 때 출력  $y_1, \dots, y_n$ 들이 서로 독립으로 출력될 확률 (독립성=1 확률)

$$\Rightarrow \prod_{i=1}^n P(y_i|x_i) = L(w|x) \rightarrow \text{최대화하는 objective 함수 model.}$$

(1)

4. 크로스 엔트로피 최적화를, 이를 최대화하는 model.

5. (1)이  $-\frac{1}{N} \ln L(w|x)$  이고.

$$\begin{aligned} \Rightarrow -\frac{1}{N} \ln \left( \prod_{i=1}^N P(y_i|x_i) \right) &= -\frac{1}{N} \sum_{i=1}^N \ln \left( \frac{1}{\sigma(w^T x_i)} \right) \Rightarrow \text{(1)번 최대화하는} \\ &= -\frac{1}{N} \sum_{i=1}^N \ln(1+e^{-y_i w^T x_i}) \text{ 을 } E_{\text{loss}} \text{ ,, -(2) (로그)} \end{aligned}$$

6. (1)번 최대화하는 문제는 (2)번 최대화하는 문제와 동등하게 같은

각 항목이 공통 조건이면 4번 항목 동등하게 서로 바꿔


$\Rightarrow$  가능한 모든  $x$  데이터 셋 ( $x_1, x_2$ )에 대해 대입했을 때의 것으로 생각

7. 어떤 데이터 셋에서 얻은 결과.

$$E_{\text{loss}}(w, x) = \ln(1+e^{w^T x})$$

• 로그 값이 큰 것일수록  $\ln(\cdot)$  값은 작은 것.

한 방향대로 1 개가 커진다면, 상용이 큰 모델이든 아니



## # Cross-Entropy Error Measure

• 두 확률변수  $P, Q$ 의 Cross-Entropy Error 다음과 같이 정의.

$$\text{ex) } P: \text{Gaussian 분포} \Rightarrow P \log \frac{1}{P} + (1-P) \log \frac{1}{1-P}$$

Q: Logistic Regression

• 어떤 확률의 결과로 최대화하는 모델은 최적화라고 하는 것임

비선형성 두 확률의 Cross-Entropy Error를 사용하는 것은 고대.