


Kernel Function (커널 함수)

- 원래의 특징공간 L 에서 정의된 두 특징벡터 x_1, x_2 에 대해 어떤 함수 $K(x_1, x_2)$ 가 다음을 만족한다면, $K(x_1, x_2)$ 를 커널함수라고 부른다.

$$\Rightarrow K(x_1, x_2) = \Phi(x_1) \cdot \Phi(x_2)$$



Vector
* 2차원이 커널(공간)을 가질 수 있음 (음의 차가)

이름 붙여주는
→ 같은 커널로 여러개의 공간
있을 수 있음.

- 신경망으로 학습한 것은 kernel function K 를 찾는 것이고, 변환함수 Φ 는 알지 못해도 됨.
- 어떤 kernel function K 이 주어지면 서로 다른 변환함수 Φ 가 존재할 수 있음.

- Kernel Trick (합리성: 손가락잡아서 가장 큰손잡은 기호가 옳음)

- $\Phi(x) \in H$ 인 공간 H 에 대하여, H 공간에서 내적 인는 $(\Phi(x_1) \cdot \Phi(x_2))$ 은 원래 특징공간 L 에서 kernel function K 을 사용하여 대체할 수 있음.
- 특정 벡터 x 를 명시적으로 H 로 변환하지 않고서도 새로운 공간에 $\Phi(x)$ 를 투영하는 효과를 얻을 수 있음. $\Rightarrow \Phi$ 를 사용하지 않음.

- Kernel substitution (커널 대체)

많이 쓰이는 Kernel Function의 예시.

- Polynomial Kernel.
 $\Rightarrow K(x_1, x_2) = (x_1 \cdot x_2 + 1)^p$ 다항식 형태
- Radial Basis Function (RBF) kernel
 $\Rightarrow K(x_1, x_2) = \exp\left(-\frac{\|x_1 - x_2\|^2}{2\sigma^2}\right)$ 가우시안 함수
- Hyperbolic tangent kernel.
 $\Rightarrow K(x_1, x_2) = \tanh(\alpha x_1 \cdot x_2 + \beta)$ tanh

* Kernel Function 자체만으로는 사용하는 변환함수 Φ 에 대한 새로운 특징공간 H 에 대한 정보가 없음. (But, ok)

SVM Recap

- Cost function
$$\mathcal{L}(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i \cdot x_j$$
 Vector 내적
- Constraints.
$$\sum_{i=1}^n \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i = 1, \dots, n$$

$$\Phi(x_i) \cdot \Phi(x_j) = K(x_i, x_j)$$

* Kernel SVM은, 선형분리 불가능한 공간 L 대신 선형분리 가능한 공간 H 에서 선형 SVM과 같음. \rightarrow 공간 내의, 주어진 Dataset.

Kernel SVM을 사용하는 이유.

- 변환된 공간 H 에서 선형분리를 허용한 것이므로, 변환함수 Φ 가 필요하다.

$$d(x) = w^T \Phi(x) + w_0$$

$$y_{pred} = \begin{cases} 1, & d(x) > 0 \\ -1, & \text{otherwise} \end{cases}$$

- 비중요도는 작게 변경하여, Φ 대신 K 의 형태로 만들 수 있게 함.

$$d(x) = w^T \cdot \Phi(x) + w_0$$

$$\begin{aligned} &= \left(\sum_{k \neq 0} \alpha_k y_k \right)^T \Phi(x) + w_0 \\ &= \sum_{k \neq 0} \alpha_k y_k \Phi(x_k) \cdot \Phi(x) + w_0 \\ &= \sum_{k \neq 0} \alpha_k y_k K(x_k, x) + w_0 \end{aligned}$$

- 미분가능에서 Kernel Func. 계산에 x_k 가 포함.

$\rightarrow \alpha_k \neq 0$ 인 sample들 (Support vectors)을 이용하여 저장하고 있어서 계산(예측)이 가능해짐. (메모리 기반 방법) \Rightarrow 한계점

\rightarrow 비선형 SVM의 예측이 정리는 새로운 Support vector의 수에 비례!